

Økonometri aflevering 1

Nikolaj Skou-Larsen - Gkm406

17-09-26

Problem 1

For at få det bedst mulige overblik over dataet laver jeg en deskriptiv analyse af datasættet. Jeg starter med at finde gennemsnittet af de tre variable samt deres standard afvigelse.

Table 1: Descriptive Statistics	
Mean (Std. Dev.)	
Tax revenue (Mio. DKK)	4,477.34 (5,251.18)
Tax rate (%)	25.21 (0.91)
Population	56,476 (62,925)
N	98

Det ses ud fra tabellen, at standardafvigelsen af skatteindtægterne og populationen er større end selve middelværdien. Det viser, at der er stor variation i dataet, med både meget store og meget små kommuner, samt en stor variation i kommunernes skatteindtægter. Tabellen viser også at skattesatsen er relativt ens i alle kommunerne med en middelværdi på 25.21% og en relativ lille standardafvigelse.

Jeg finder også minimum og maximum værdierne af både skatteindtægt og skattesats, hvor jeg kan se ydre punkterne af dataet. Resultaterne kan ses i tabel 2.

Table 2: Maximum and minimum values of tax revenue and tax rate				
Category	Municipality	Tax revenue (mio. DKK)	Tax rate (%)	Population
Max tax revenue	Københavns	44,170.3	23.8	528,208
Min tax revenue	Læsø	211.2	25.6	1,969
Max tax rate	Langeland	1,185.7	27.8	13,510
Min tax rate	Gentofte	5,112.3	22.8	71,052

Her kan jeg bekræfte den store standardafvigelse for skatteindtægterne. Hvor København og Læsø har en forskel i skatteindkomst på 43,959 mio. DKK. Det samme gælder for populationen, hvor København og Læsø har ekstremt stor forskel i indbyggertal. Den store forskel er med til at forklare, hvorfor standardafvigelsen er så stor. Dog betyder det ikke nødvendigvis at København og Læsø er outliers, men repræsenterer ydre punkterne i datasættet. Jeg kan også se at skattesatsen ligger meget ens, hvor forskellen på minimum og maksimums værdierne er 5 procentpoint.

Problem 2

2.1

I modellen angiver δ_1 , hvilken indvirkning skatteraten har på skatteindkomsterne for kommunerne. Præcist er modellen en Log-Level model, hvori at $\delta_1 \cdot 100$ angiver den procentvise ændring i skatteindtægterne. δ_1 er altså den forklarende variable, og er hældningen på regressionslinjen.

2.2

Forventningen til modellen er, at $\delta_1 > 0$, da en højere skattesats i teorien giver en højere indtjening på hver krone. Den samme mængde arbejde af borgerne vil give højere skatteindtægter, hvis ceteris paribus holder. Hvilket gør at forventningen til δ_1 er positiv.

Dog medfører en forhøjet skattesats en modarbejdende effekt da en for høj skattesats vil sænke skatteindtægterne grundet, at incitamentet til at arbejde bliver sænket. Det bliver beskrevet af laffer kurven, hvori en skattesats på 0% giver en indtægt på nul, mens en skattesats på 100% også giver en skatteindtægt på nul da fortjenesten ved at arbejde forsvinder hos borgerne. Denne effekt forventer jeg ikke er stor nok til at have nogle form for betydende effekt i regressionen.

2.3

OLS regressionens resultater kan ses i tabel 3. Regressionen giver mig $\hat{\delta}_1 = -0.143$, hvilket betyder at en stigning i skattesatsen på et procentpoint skaber en ændring i skatteindtægterne på omkring -14.3% . Altså har en stigning i skattesatsen en kæmpe negativ effekt på indtægterne. Det går altså imod forventningen til at en højere skattesats vil give højere skatteindtægter.

Table 3: OLS Regression Results

	Coefficient	Std. Error	R-squared
$\hat{\delta}_0$	11.6982	2.1430	0.0285
$\hat{\delta}_1$	-0.1426	0.0850	0.0285

Regressionen giver $R^2 = 0.029$, hvilket betyder at 2.9% af variationen i skatteindtægterne er forklaret af skattesatsen. Dermed vil resten af variationen være forklaret i fejllede. Det viser altså, at skatteraten ikke er den primære årsag til variationen af skatteraten. Regressionen angiver også $\hat{\delta}_0 = 11.698$, hvilket viser at skatteindtægterne stadig vil være 11.7 mio. selv med en skattesats på nul. Det giver ikke nogle økonomisk mening og derfor giver det ikke mening at kigge mere på $\hat{\delta}_0$.

2.4

I den første model er populationens effekt en del af fejllede, hvor at den er blevet en forklarende variable i model 2. Forskellen mellem δ_1 og β_1 er at i model 1 bliver effekten af populationen ikke holdt konstant grundet den ligger i fejllede. Det betyder at populationen kan have en effekt på skatteindtægterne som ikke bliver fanget af δ_1 . I den anden model viser β_1 effekten på skatteindtægterne når populationen holdes konstant. Altså bliver β_1 kontrolleret for den effekt som populationen har.

2.5

OLS regressionen giver mig $\hat{\beta}_1 = 0.0226$, hvilket betyder at en stigning i skatteraten på et procentpoint giver en 2.26% stigning i indtægterne. Det var også den forventning jeg havde til regressionen i 2.2. I model 1 fik jeg at en stigning i skatteraten vil reducere skatteindtægterne, hvilket kan tyde på at populationen har en stor indvirkning på skattesatsen. Det ses også når man kigger på tabel 2, hvor både langeland og Læsø har en høj skat med lav population og København og gentofte har en relativ lav skat men en høj population. Intuitivt også mening fordi der er flere mennesker, som kan bidrage til skatteindtægterne, der dermed sænker nødvendigheden for at sætte en høj skattesats. Derfor hentyder det til at MLR.4, $E[u|X] = 0$ ikke holder i model 1, netop fordi det tyder på at populationen har indflydelse på skattesatsen. Det er altså tegn på at populationen er en udeladt variable. Dermed viser regressionen at skatteraten muligvis er endogen i model 1.

Table 4: OLS Regression Results

	Coefficient	Std. Error	R-squared
$\hat{\beta}_0$	-2.8022	0.3756	0.9801
$\hat{\beta}_1$	0.0226	0.0125	0.9801
$\hat{\beta}_2$	0.9711	0.0144	0.9801

Den anden forklarende variable bliver til $\hat{\beta}_2 = 0.9711$. Da modellen bruger $\log(pop)$ bliver modellen til en log-log model. Hvilket betyder at $\hat{\beta}_2 = 0.9711$ er en elasticitet, som beskriver en 1% stigning i populationen giver en 0.97% stigning i skatteindtægterne. Det viser at der er en tæt sammenhæng mellem skatteindtægterne og populationen.

I OLS regressionen af model 2 er $R^2 = 0.98$, hvilket betyder at 98% af variationen af skatteindtægt er forklaret af modellen. Dermed er modellen meget god til at forklare næsten alt af variationen i skatteindtægterne.

Herunder kan jeg sammenligne R^2 fra model 1 og 2. Hvor der er en stigning på 95.1 procentpoint ved indførelsen af populationen. Det viser at populationen er meget vigtigt for at forklare variationen i skatteindtægterne.

2.6

Omitted variable bias, betyder at man udlader en variable i modellen, som muligvis er korreleret med en anden variable i modellen. Det betyder at den udeladte variable vil blive opfanget af fejllede. Det er dårligt, da en af CLM antagelserne netop er at alle variablene ikke er korreleret med fejllede. Der skal gælde for at man får en unbiased OLS estimator at

$$E[u|X] = 0$$

altså at fejllede ikke afhænger af nogle af de forklarende variable. Hvis $E[u|X] \neq 0$ kan det give estimatoren bias. Det kan ses, hvis jeg antager at model 2 er den sande model bliver model 1 den underspecificeret model. Dermed skriver jeg model 1 som,

$$y = \tilde{\beta}_0 + \tilde{\beta}_1 x_1 + \tilde{u}$$

hvor $\tilde{\beta}_1$ kan være korreleret med β_2 og $x_1 = \text{taxrate}$. Jeg kan udregne OLS estimatoren for modellen.

$$\tilde{\beta}_1 = \frac{\sum_{i=1}^n y_i (x_{i1} - \bar{x}_1)}{\sum_{i=1}^n (x_{i1} - \bar{x}_1)^2}$$

Hvis jeg omskriver dette ender jeg med at få (se 03.mlr, slide 42.).

$$E[\tilde{\beta}_1|X] = \beta_1 + \beta_2 \frac{\text{cov}(x_1, x_2)}{\text{var}(x_1)} = \beta_1 + \beta_2 \frac{\text{cov}(\text{taxrate}, \log(\text{pop}))}{\text{var}(\text{taxrate})}$$

Her ses det at, hvis covariansen mellem skattesatsen og populationen er korreleret vil estimatoren ikke være middelfret og dermed være biased. Størrelsen af den bias, der bliver pålagt kommer altså an på størrelsen af β_2 og covariansen mellem *taxrate* og *log(pop)*. For at finde ud af, hvilken virkning covariansen har bruger jeg tabel 5 (Table 3.2 fra Wooldridge).

Table 5: Summary of Bias in $\hat{\beta}_1$ when x_2 is Omitted

	$\text{Corr}(x_1, x_2) > 0$	$\text{Corr}(x_1, x_2) < 0$
$\beta_2 > 0$	Positive bias	Negative bias
$\beta_2 < 0$	Negative bias	Positive bias

Jeg husker fra min OLS regression på den sande model at $\hat{\beta}_2 > 0$ og at $\hat{\beta}_1 > \hat{\delta}_1$. Det betyder altså at populationen pålægger $\hat{\delta}_1$ en negativ bias. Altså vil δ_1 være for lavt ift. den sande model, som også er vist af OLS regressionerne. Givet det kan jeg ud fra tabellen konkludere at $\text{Corr}(x_1, x_2) < 0$ og at $\text{cov}(x_1, x_2) < 0$ på baggrund af $\hat{\beta}_2 > 0$ samt at δ_1 bliver tillagt en negativ bias. Det viser, altså at en højere population vil give kommunen en lavere skattesats, hvilket også giver god intuitiv mening. De store kommuner kan sænke skattesatsen fordi der allerede er mange, som betaler skat, hvor i de små kommuner bliver skattesatsen presset op sådan at deres skatteindtægter ikke bliver for lave.

Problem 3

3.1

Den lineære model er givet som ved ,

$$y = \beta_1 x_1 + \beta_2 x_2 + u$$

hvilket kan skrives på matrix form som,

$$y = \beta X + u$$

hvor

$$y = \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix}, \quad X = \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ \dots & \dots \\ x_{n1} & x_{n2} \end{bmatrix}, \quad \beta = \begin{bmatrix} \beta_1 \\ \beta_2 \end{bmatrix}.$$

Jeg ved fra formlen for estimatoren at β er givet ved,

$$\hat{\beta} = (X'X)^{-1}X'y$$

derfor starter jeg med at finde produktet $X'X$. Siden X er en $n \times 2$ matrix er X' en $2 \times n$. Derfor bliver $X'X$ en 2×2 matrix.

$$X'X = \begin{bmatrix} x_{11} & x_{21} & \dots & x_{n1} \\ x_{12} & x_{22} & \dots & x_{n2} \end{bmatrix} \begin{bmatrix} x_{11} & x_{12} \\ x_{21} & x_{22} \\ \dots & \dots \\ x_{n1} & x_{n2} \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n x_{i1}^2 & \sum_{i=1}^n x_{i1}x_{i2} \\ \sum_{i=1}^n x_{i1}x_{i2} & \sum_{i=1}^n x_{i2}^2 \end{bmatrix}$$

For at finde den inverse matrix bruger jeg reglen for en 2×2 symmetrisk matrix A at,

$$A^{-1} = \frac{1}{\det(A)} \begin{bmatrix} d & -b \\ -b & a \end{bmatrix}.$$

Dermed bliver den inverse

$$(X'X)^{-1} = \frac{1}{\sum_{i=1}^n x_{i1}^2 \sum_{i=1}^n x_{i2}^2 - \sum_{i=1}^n (x_{i1}x_{i2})^2} \begin{bmatrix} \sum_{i=1}^n x_{i2}^2 & -\sum_{i=1}^n x_{i1}x_{i2} \\ -\sum_{i=1}^n x_{i1}x_{i2} & \sum_{i=1}^n x_{i1}^2 \end{bmatrix}.$$

Da jeg skal finde β skal jeg også bruge $X'y$, hvilket er bliver en 2×1 matrix.

$$X'y = \begin{bmatrix} x_{11} & x_{21} & \dots & x_{n1} \\ x_{12} & x_{22} & \dots & x_{n2} \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ \dots \\ y_n \end{bmatrix} = \begin{bmatrix} \sum_{i=1}^n x_{i1}y_i \\ \sum_{i=1}^n x_{i2}y_i \end{bmatrix}$$

Nu jeg kan finde $\hat{\beta}$ matricen.

$$\begin{aligned} (X'X)^{-1}X'y &= \frac{1}{\sum_{i=1}^n x_{i1}^2 \sum_{i=1}^n x_{i2}^2 - \sum_{i=1}^n (x_{i1}x_{i2})^2} \begin{bmatrix} \sum_{i=1}^n x_{i2}^2 & -\sum_{i=1}^n x_{i1}x_{i2} \\ -\sum_{i=1}^n x_{i1}x_{i2} & \sum_{i=1}^n x_{i1}^2 \end{bmatrix} \begin{bmatrix} \sum_{i=1}^n x_{i1}y_i \\ \sum_{i=1}^n x_{i2}y_i \end{bmatrix} \\ &= \frac{1}{\sum_{i=1}^n x_{i1}^2 \sum_{i=1}^n x_{i2}^2 - \sum_{i=1}^n (x_{i1}x_{i2})^2} \begin{bmatrix} \sum_{i=1}^n x_{i2}^2 \sum_{i=1}^n x_{i1}y_i - \sum_{i=1}^n x_{i1}x_{i2} \sum_{i=1}^n x_{i2}y_i \\ -\sum_{i=1}^n x_{i1}y_i \sum_{i=1}^n x_{i1}y_i + \sum_{i=1}^n x_{i1}^2 \sum_{i=1}^n x_{i2}y_i \end{bmatrix} \end{aligned}$$

Siden jeg kun skal finde et udtryk for $\hat{\beta}_1$ så bruger jeg at $\hat{\beta} = \begin{bmatrix} \hat{\beta}_1 \\ \hat{\beta}_2 \end{bmatrix}$ hvilket giver

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_{i2}^2 \sum_{i=1}^n x_{i1}y_i - \sum_{i=1}^n x_{i1}x_{i2} \sum_{i=1}^n x_{i2}y_i}{\sum_{i=1}^n x_{i1}^2 \sum_{i=1}^n x_{i2}^2 - \sum_{i=1}^n (x_{i1}x_{i2})^2}$$

som jeg kan dividere med $\sum_{i=1}^n x_{i2}^2$, hvilket vil give mig udtrykket.

$$\hat{\beta}_1 = \frac{\sum_{i=1}^n x_{i1}y_i - \frac{\sum_{i=1}^n x_{i1}x_{i2}}{\sum_{i=1}^n x_{i2}^2} \sum_{i=1}^n x_{i2}y_i}{\sum_{i=1}^n x_{i1}^2 - \frac{\sum_{i=1}^n (x_{i1}x_{i2})^2}{\sum_{i=1}^n x_{i2}^2}}$$

3.2

Opgaven beskriver Frisch-Waugh-Lovell teoremet. For at vise at man for samme estimator ved model 3 starter jeg med at regresser x_1 på x_2 , hvor r_1 er residualerne.

$$x_1 = \beta_2 x_2 + r_1$$

Hvilket ved OLS giver mig

$$x_1 = \hat{\beta}_2 x_2 + \hat{r}_1 \Rightarrow \hat{r}_1 = x_1 - \hat{\beta}_2 x_2$$

Fra Wooldridge formel (2.66) har jeg at estimatoren uden intercept er givet ved,

$$\hat{\beta}_2 = \frac{\sum_{i=1}^n x_{i2} x_{i1}}{\sum_{i=1}^n x_{i2}^2}$$

hvilket giver mig et udtryk fra residualerne

$$\hat{r}_1 = x_{i1} - \frac{\sum_{i=1}^n x_{i2} x_{i1}}{\sum_{i=1}^n x_{i2}^2} x_{i2}$$

Nu kan jeg regresser y på $\hat{r}_1$. Igen bruger jeg formel (2.66) til at få estimatoren $\hat{\beta}_1$.

$$y_i = \beta_1 \hat{r}_1 + u_i$$

$$\begin{aligned} \hat{\beta}_1 &= \frac{\sum_{i=1}^n \hat{r}_1 y_i}{\sum_{i=1}^n \hat{r}_1^2} = \frac{\sum_{i=1}^n \left(\left(x_{i1} - \frac{\sum_{i=1}^n x_{i1} x_{i2}}{\sum_{i=1}^n x_{i2}^2} x_{i2} \right) y_i \right)}{\sum_{i=1}^n \left(x_{i1} - \frac{\sum_{i=1}^n x_{i1} x_{i2}}{\sum_{i=1}^n x_{i2}^2} x_{i2} \right)^2} \\ &= \frac{\sum_{i=1}^n x_{i1} y_i - \frac{\sum_{i=1}^n x_{i1} x_{i2}}{\sum_{i=1}^n x_{i2}^2} \sum_{i=1}^n x_{i2} y_i}{\sum_{i=1}^n x_{i1}^2 - \frac{\sum_{i=1}^n (x_{i2} x_{i1})^2}{\sum_{i=1}^n x_{i2}^2}} \end{aligned}$$

Her ser jeg altså, at jeg for præcist den samme estimator fra Frisch-Waugh Lovell teoremet, som i opgave 3.1. Dermed vil begge metoder give samme estimator.

3.3

Resultaterne for den første regression af *taxrate* på *log(pop)* kan ses i tabel 6.

Table 6: OLS Regression Results *taxrate* on *log(pop)*

	Coefficient	Std. Error	R-squared
$\hat{\beta}_0$	27.6268	1.2341	0.0387
$\hat{\beta}_1$	-0.2273	0.1156	0.0387

Her bliver estimatet $\hat{\beta}_1 = -0.2273$, hvilket viser en negativ sammenhæng mellem skattesatsen og populationen. Da regressionen er en level-log model betyder $\hat{\beta}_1$ at en stigning i populationen på 1% ændre skattesatsen med omkring

$$\Delta \text{taxrate} = -\frac{0.2273}{100} = -0.00273.$$

Denne regression bekræfter også konklusionen af opgave 2, nemlig at populationen er negativt korreleret med skattesatsen.

Regressionen af $\log(\text{taxrev})$ på $\hat{r}_1$ kan ses i tabel 7. Her kan jeg se at $\hat{\beta}_1 = 0.0226$, hvilket er præcist den samme værdi som i 2.5. Jeg får altså samme resultat med Frisch-Waugh-Lovell(FWL) som med OLS regressionen på den sande model. Det betyder altså, at FWL korrigerer estimatet for $\log(\text{pop})$.

Table 7: OLS Regression Results $\log(\text{taxrev})$ on $\hat{r}_1$

	Coefficient	Std. Error	R-squared
$\hat{\beta}_0$	8.1031	0.0778	0.0007
$\hat{\beta}_1$	0.0226	0.0879	0.0007

Estimatet bliver korrigeret i første regression, hvor variationen af taxrate kan skrives som,

$$\text{taxrate} = \widehat{\text{taxrate}} + \hat{r}_1$$

hvilket er den variation som populationen forklarer $\widehat{\text{taxrate}}$, og den del, som ikke bliver forklaret $\hat{r}_1$. Dermed er $\hat{r}_1$ allerede korrigeret for populationen, hvilket betyder at $\hat{r}_1$ er ukorreleret med $\log(\text{pop})$. Det medfører at estimatet $\hat{\beta}_1$ i den anden regression ikke får omitted variable bias fra $\log(\text{pop})$.

Problem 4

Konklusionen af opgaven er, at skatteindtægterne bliver påvirket positivt af både skattesatsen og populationen. Indtægterne afhænger mest af populationen, som ved en 1% stigning i populationen giver en stigning på 0.97% i skatteindtægterne. Hvorefter en stigning på skattesatsen på ét procent point får skatteindtægterne til at stige med 2.26%. Jeg fandt også frem til at en højere population sænker den forventede skattesats, hvilket altså viser en negativ korrelation mellem skattesatsen og populationen. Det er på baggrund af både Frisch-Waugh-Lovell teoremet og på en regression med en udeladt variable. Det betyder at store kommuner med mange borgere, som betaler skat, kan få tilstrækkelige indtægter selvom skattesatsen er lavere end de små kommuner.